

Mettez en place un pipeline d'orchestration des flux

Automatisation ETL avec Kestra, DuckDB, Python et Docker

Contexte du projet

BottleNeck est un marchand de vin basé à Paris, qui s'adresse à la fois à des clients professionnels et à des clients particuliers.

BottleNeck gère ses données de vins à travers plusieurs systèmes :

- **ERP** : données produits, prix et stocks
- **CMS/Web** : données de vente en ligne
- **Fichier de liaison** : mapping entre les identifiants ERP et Web

Défi du projet :

La réconciliation des données, l'analyse et le reporting mensuel étaient manuels, répétitifs et exposés aux erreurs.

Objectif principal :

Industrialiser l'analyse manuelle en construisant un workflow automatisé avec Kestra.

Le workflow doit :

1- Automatiser la chaîne de transformation des données

Charger les trois fichiers sources, nettoyer et dédupliquer les données, réconcilier les données ERP et CMS/Web, calculer le chiffre d'affaires et identifier les vins premium et ordinaires.

2- Générer les livrables métier attendus

- un rapport Excel avec le chiffre d'affaires par produit et le chiffre d'affaires total ;
- deux extractions CSV : premium_wines.csv et ordinary_wines.csv.

3- Planifier l'exécution mensuelle

Tous les 15 du mois à 09h00.

4- Valider la qualité des résultats

Tests de volumétrie, clés manquantes, doublons, chiffre d'affaires total et nombre de vins premium.


5- Gérer les échecs du workflow

Retries sur les tâches techniques et rapport d'échec en cas d'erreur.

Approche technique


La solution sépare l'orchestration du traitement des données: Kestra coordonne le workflow, mais les traitements sont réalisés par DuckDB et Python.

Composant	Rôle
Kestra	Orchestre, planifie, supervise, gère les tentatives de relance et les erreurs
DuckDB	Transformations SQL, jointures, tests et exports CSV
Python	Conversion Excel, calcul du z-score et export Excel
Docker	Environnement local reproductible
PostgreSQL	Stockage des métadonnées Kestra



End-to-End Workflow Architecture

End-to-End ETL Workflow - Automated Kestra Data Orchestration Pipeline for BottleNeck Revenue Analysis & Wine Classification



Motasem Abualqumboz

Préparation des sources et logique de fusion

1. Conversion des fichiers Excel en CSV

erp.xlsx → erp.csv
web.xlsx → web.csv
liaison.xlsx → liaison.csv

2. Nettoyage avec DuckDB

Dataset	Règle de nettoyage	Output
erp.csv	Supprimer les lignes où product_id est manquant, puis supprimer les doublons	erp_clean.csv
web.csv	Supprimer les lignes où sku est manquant, puis dédupliquer par sku	web_clean.csv
liaison.csv	Supprimer les lignes en doublon	liaison_clean.csv

3. Tests de validation

Tests sur les sources nettoyées :

- ERP = 825 lignes
- Web = 714 lignes
- Liaison = 825 lignes
- Aucune clé métier manquante
- Aucun doublon sur les clés métier

4. Clés de fusion utilisées après nettoyage

Join logic:

ERP.product_id = Liaison.product_id

Liaison.id_web = Web.sku

Résultat attendu après fusion :

714 produits réconciliés

Test après Merge :

Merged = 714 lignes

Calcul et validation du chiffre d'affaires

Le workflow calcule le chiffre d'affaires au niveau produit :

$$\text{revenue} = \text{price} \times \text{total_sales}$$

Fichiers intermédiaires générés :

- merged_with_revenue.csv
- revenue_per_product.csv

Validation checks:

Test	Résultat attendu
Nombre de lignes du rapport	714 lignes
Valeurs revenue manquantes	0
Chiffre d'affaires total	70,568.60 €

Détection des vins premium avec le z-score

Les vins premium sont détectés avec la méthode du z-score appliquée aux prix.

$$z_score = (\text{prix du vin} - \text{prix moyen}) / \text{écart type des prix}$$

Règle métier :

Type de vin	Règle
Premium wine	$z_score > 2$
Ordinary wine	$z_score \leq 2$

Contrôle de validation :

Nombre attendu de vins premium = 30

Livrables finaux

Le workflow génère trois livrables métier dans data/outputs/.

Fichier de sortie	Généré par	Objectif
revenue_per_product.xlsx	Python	Chiffre d'affaires par produit + synthèse du chiffre d'affaires total
premium_wines.csv	DuckDB	Liste des vins où z_score > 2
ordinary_wines.csv	DuckDB	Liste des vins où z_score <= 2

Point clé :

Les exports CSV sont générés avec DuckDB, tandis que le rapport Excel est généré avec Python.

Planification avec Kestra

Le workflow est planifié pour s'exécuter automatiquement chaque mois.

triggers:

- id: monthly_schedule

```
type: io.kestra.plugin.core.trigger.Schedule  
cron: "0 9 15 * *"  
timezone: Europe/Paris
```

Signification du planning :

Tous les mois, le 15, à 09h00

Test effectué :

Pour vérifier le trigger, la planification a été temporairement changée à une exécution toutes les 2 minutes.

Gestion des erreurs et stratégie de retry

Le workflow inclut deux niveaux de gestion des erreurs.

Mécanisme

Retries

Bloc global errors:

Objectif

Relancer les échecs techniques temporaires

Créer un rapport d'échec si le workflow échoue

Stratégie de retry :

- Appliquée uniquement aux tâches techniques
- 3 tentatives
- 30 secondes entre les tentatives
- Les tâches de validation ne sont pas relancées

Emplacement du rapport d'échec :

data/outputs/error_logs/

Limites et améliorations possibles

Implémentation actuelle :

- Projet local basé sur Docker
- Stockage local avec dossiers montés
- Rapport d'échec local simple

Améliorations possibles :

- Ajouter des alertes Slack ou e-mail
- Centraliser les logs et le monitoring
- Remplacer le stockage local par un stockage cloud
- Ajouter un dashboard métier

Démonstration

Objectif de la démonstration :

Prouver que le workflow s'exécute de bout en bout et génère les livrables métier attendus.

Pendant la démonstration :

- Présenter la topologie du workflow dans Kestra
- Exécuter le workflow Kestra
- Vérifier le statut de réussite et les logs de validation
- Présenter les livrables générés : rapport Excel et fichiers CSV

Conclusion

Le projet transforme un processus d'analyse manuel en pipeline de données automatisé et fiable.

Résultat final :

- Workflow mensuel automatisé avec Kestra
- Données ERP/Web nettoyées, réconciliées et validées
- Rapport du chiffre d'affaires généré en Excel
- Extractions des vins premium et ordinaires générées en CSV
- Gates de qualité des données et gestion des erreurs implémentées